Projeto MPEI - 25/26

PREVISÕES METEOROLÓGICAS

Miguel Neto (125200) & Diogo Silva (125240)



INTROUDÇÃO E CONTEXTO

Este projeto visa implementar os diferentes módulos lecionados (Naive-Bayes, Bloom Filter e MinHash) de modo a realizar previsões meteorológicas.

Os datasets utilizados foram obtidos em Open-Meteo, uma API open-source com dados meteorológicos. Adicionalmente, foi desenvolvido um script MATLAB de modo a categorizar os vários tipos no dataset.

Foi feita uma categorização dos dados númericos em *tokens* (ex: temp_alta), para os módulos MinHash e Bloom Filter.





PIPELINE

01 Leitura de Dados

02 Inicialização dos módulos

03 Análise com Algoritmos

04 Geração de Previsões

NAIVE-BAYES



Para cada classe meteorológica, o modelo estima a média e desvio-padrão de cada atributo durante o treino, calculando também o logaritmo da probabilidade a priori com base na frequência relativa. Na predição, aplica a regra de Bayes com independência condicional entre features com a seguinte fórmula:

$$\log P(c|x) \propto \log P(c) + \Sigma_j \log N(x_j \mid \mu_{cj}, \sigma_{cj})$$

O cálculo em espaço logarítmico evita underflow numérico, com normalização por subtração do máximo antes de exponenciar.

BLOOM FILTER

Responsável por deteção de novidade, i.e, padrões de condições atmosféricas nunca antes vistas.

Os *tokens* são concatenados numa única string longa por dia (ex: "temp_alta_hum_media"), servindo de chave para detectar tais padrões.

Utilizámos $k = (m/n) * \ln 2 \approx 4$, com um mecanismo de Double Hashing, que utiliza duas funções de dispersão:

- a primeira determina a posição inicial da chave.
- a segunda define o intervalo entre tentativas em caso de colisão.



BLOOM FILTER

Assim, as k = 4 posições são geradas através da seguinte fórmula: $pos = (h1 + i*h2) \pmod m + 1, i \in \{0,1,2,3\}$.

Esta abordagem permite simular o comportamento de 4 funções independentes com o custo computacional de apenas duas.



MINHASH

Responsável pela deteção de padrões semelhantes no histórico. Extrai as 20 amostras mais parecidas de cada classe, calculando a sua média. O resultado é convertido num vetor de probabilidades que ajuda a ponderar a decisão final.

O sistema foi configurado para utilizar 200 funções de dispersão independentes para gerar as assinaturas, o que permite obter um compromisso entre a precisão da estimativa e o custo computacional.

ENTROPIA DE SHANNON

A Entropia de Shannon é uma métrica que mede o grau de incerteza associado a uma distribuição de probabilidades. A sua definição é dada por:

$$-\sum_{i=1}^{n} P(x_i)\, log_2\, P(x_i)$$

Entropia Máxima: Ocorre quando todas as categorias têm exatamente a mesma probabilidade de acontecer. O sistema está em máxima incerteza.
Entropia Mínima: Ocorre quando um resultado é absolutamente certo.

Foi utilizada para ajustar dinamicamente os pesos da previsão, atribuindo maior importância ao Naive-Bayes quando a sua confiança era elevada e aumentando o contributo do MinHash em situações de maior ambiguidade.

DEMONSTRAÇÃO

RESULTADOS

De modo geral, o pipeline aumenta ligeiramente a precisão das previsões, ainda que essa diferença não seja muito significativa, devido à entropia.

O sistema desenvolvido tem uma alta precisão, em diferentes datasets, o que demonstra uma harmonia entre os vários módulos.

PRECISÃO DAS PREVISÕES (MÉDIA)

90%

TEMPO DE PROCESSAMENTO ATUAL (MÉDIA)

4 SEG

LIMITAÇÕES E MELHORIAS

Devido a limitações do Open-Meteo, não conseguimos obter os campos necessários para **distinguir** de modo exímio os **diferentes tipos de chuva**, o que é o maior ponto fraco do sistema.
Além disso, há certas coisas que queriamos adicionar mas que não foram pois pioravam os resultados, nomeadamente

- O atributo de **Dew Point (Ponto de Orvalho)**, correspondente à temperatura à qual o ar deve ser arrefecido para ficar completamente saturado de humidade. Era pretendido para ajudar na previsão de nevoeiro, mas acabou por piorar os resultados finais 1 a 2% idependentemente do dataset usado
- A categoria de tempo N**ebulado (cloudy)**; os datasets contêm informação para tal, os WMO Codes 2 e 3 são reservados para isso; no entanto, este tipo de tempo é muito abrangente e com os restantes atributos do dataset, os resultados da pipeline com esta categoria eram quase sempre 5 a 10% piores do que sem.

CONCLUSÃO

Este projeto demonstrou com sucesso a implementação de um sistema de previsões meteorológicas funcional e preciso, com recursos aos módulos pretendidos.

Existe espaço para melhoria, principalmente na questão dos datasets, que infelizmente não podemos controlar.

De modo geral, o projeto permitiu desenvolver conhecimentos a nível da implementação prática de métodos probabilísticos e o seu funcionamento.

